ПРОГРАММНАЯ МОДЕЛЬ CUDA. ПАРАЛЛЕЛЬНОЕ СЛОЖЕНИЕ ВЕКТОРОВ НА GPU СРЕДСТВАМИ CUDA.

АФАНАСЬЕВ ИЛЬЯ
AFANASIEV_ILYA@ICLOUD.COM

CUDA: ГИБРИДНОЕ ПРОГРАММИРОВАНИЕ

- **CUDA** (изначально аббр. от англ. Compute Unified Device Architecture) – программно-аппаратная архитектура параллельных вычислений, которая позволяет разрабатывать программы для графических процессоров NVIDIA
- Программа, использующая GPU, состоит из:
    - Кода для GPU, описывающего вычисления, выполняемые на графическом ускорителе
    - Кода для CPU, в котором осуществляется:
        - Управление памятью GPU - выделение / освобождение
        - Обмен данными между GPU/CPU
        - Запуск **кода для GPU**
        - Обработка результатов и прочий последовательный код

ТЕРМИНОЛОГИЯ (КОД)

- CPU будем далее называть **«хостом»** (от англ. host), код для CPU - код для хоста, **«хост-код»** (host-code)
- GPU будем далее называть **«устройством»** или **«девайсом»** (от англ. device), код для GPU – **«код для устройства», «девайс-код»** (device-code)
- Хост выполняет последовательный код (а при необходимости и параллельный), в **котором содержатся вызовы функций управления устройством**

CUDA-ПРОГРАММА

(HOST CODE + DEVICE CODE)

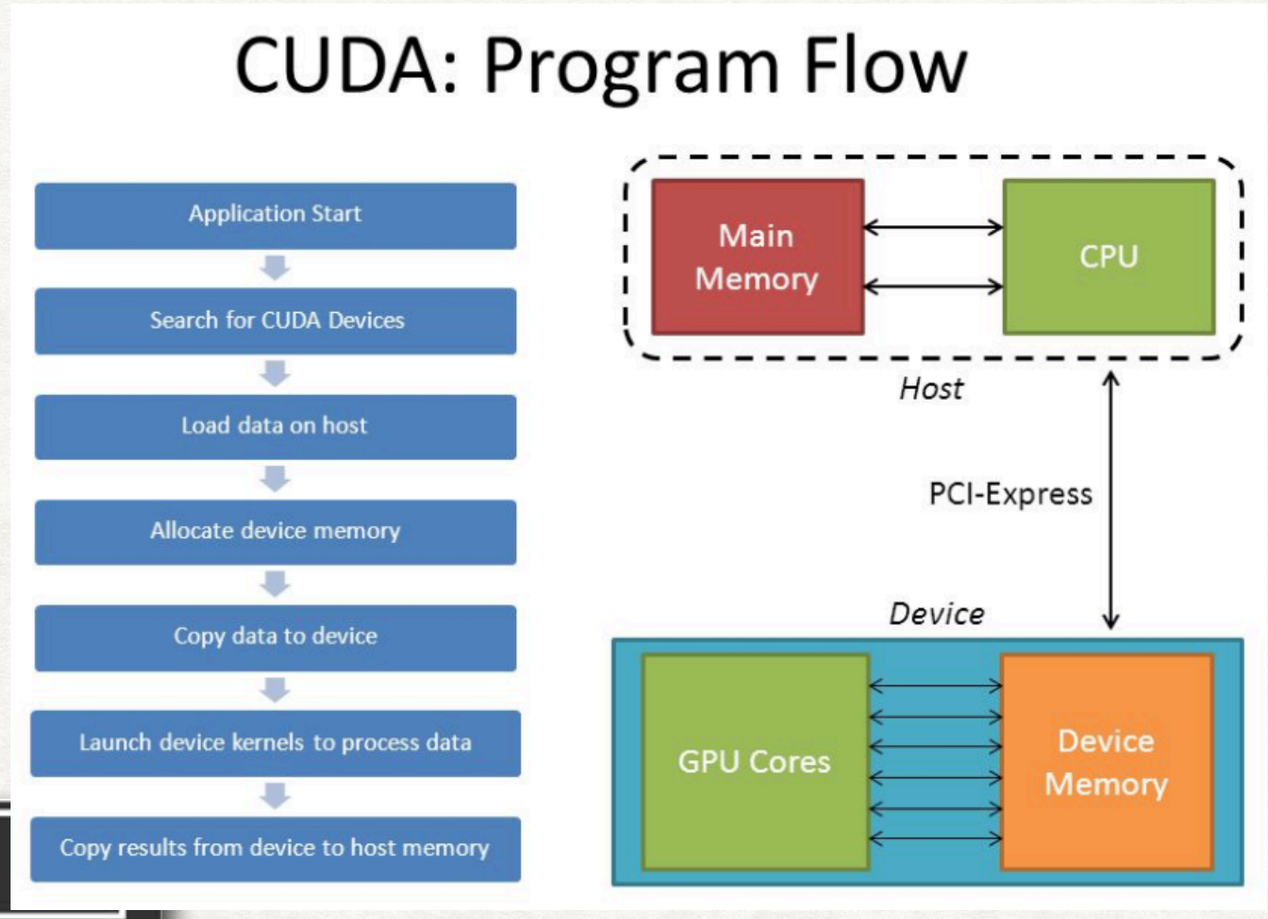

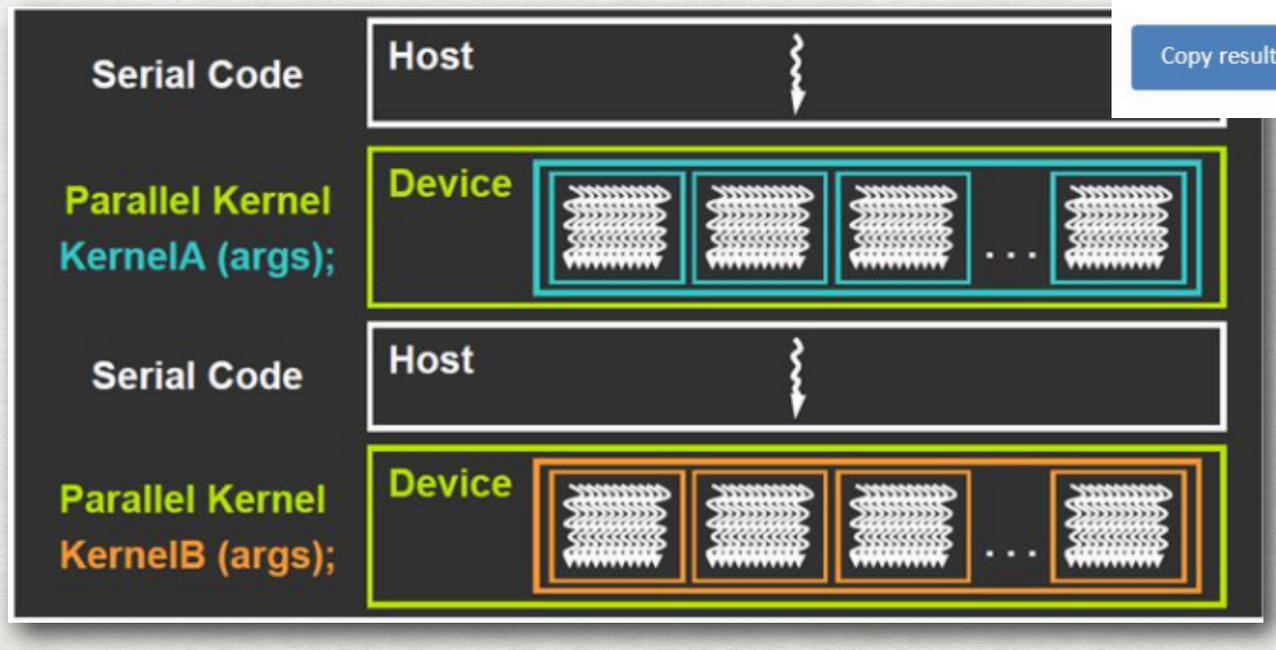

КАК ХОСТ-КОД ВЗАИМОДЕЙСТВУЕТ С GPU?

- Код для CPU дополняется вызовами **специальных функций для работы с устройством** – выделение памяти, копирования данных, получение свойств GPU
- Код для CPU может компилироваться обычным компилятором GCC/ICC (с подключением специальных библиотек)
    - Кроме конструкций запуска ядра <<<...>>> !
- Возможна компиляция всего кода с использованием компилятора NVCC (доступен в CUDA Toolkit, предустановлен на кластерах)
- Функции для GPU линкуются из динамических библиотек (если используется обычный компилятор)

КОД ДЛЯ GPU (DEVICE-CODE)

- Код для GPU пишется на C++ с некоторыми расширениями:
  - Атрибуты функций, переменных и структур
  - Встроенные функции
  - Математика, реализованная на GPU
  - Синхронизации, коллективные операции
  - Векторные типы данных
  - Встроенные переменные:
    threadIdx, blockIdx, gridDim, blockDim
  - Шаблоны для работы с текстурами
- GPU-код компилируется специальным компилятором NVCC (входящим в состав CUDA Toolkit)

ПРИМЕР: СЛОЖЕНИЕ ВЕКТОРОВ

```
CPU:
for(int i=0; i<N; ++i)
      c[i]= a[i] + b[i];
```

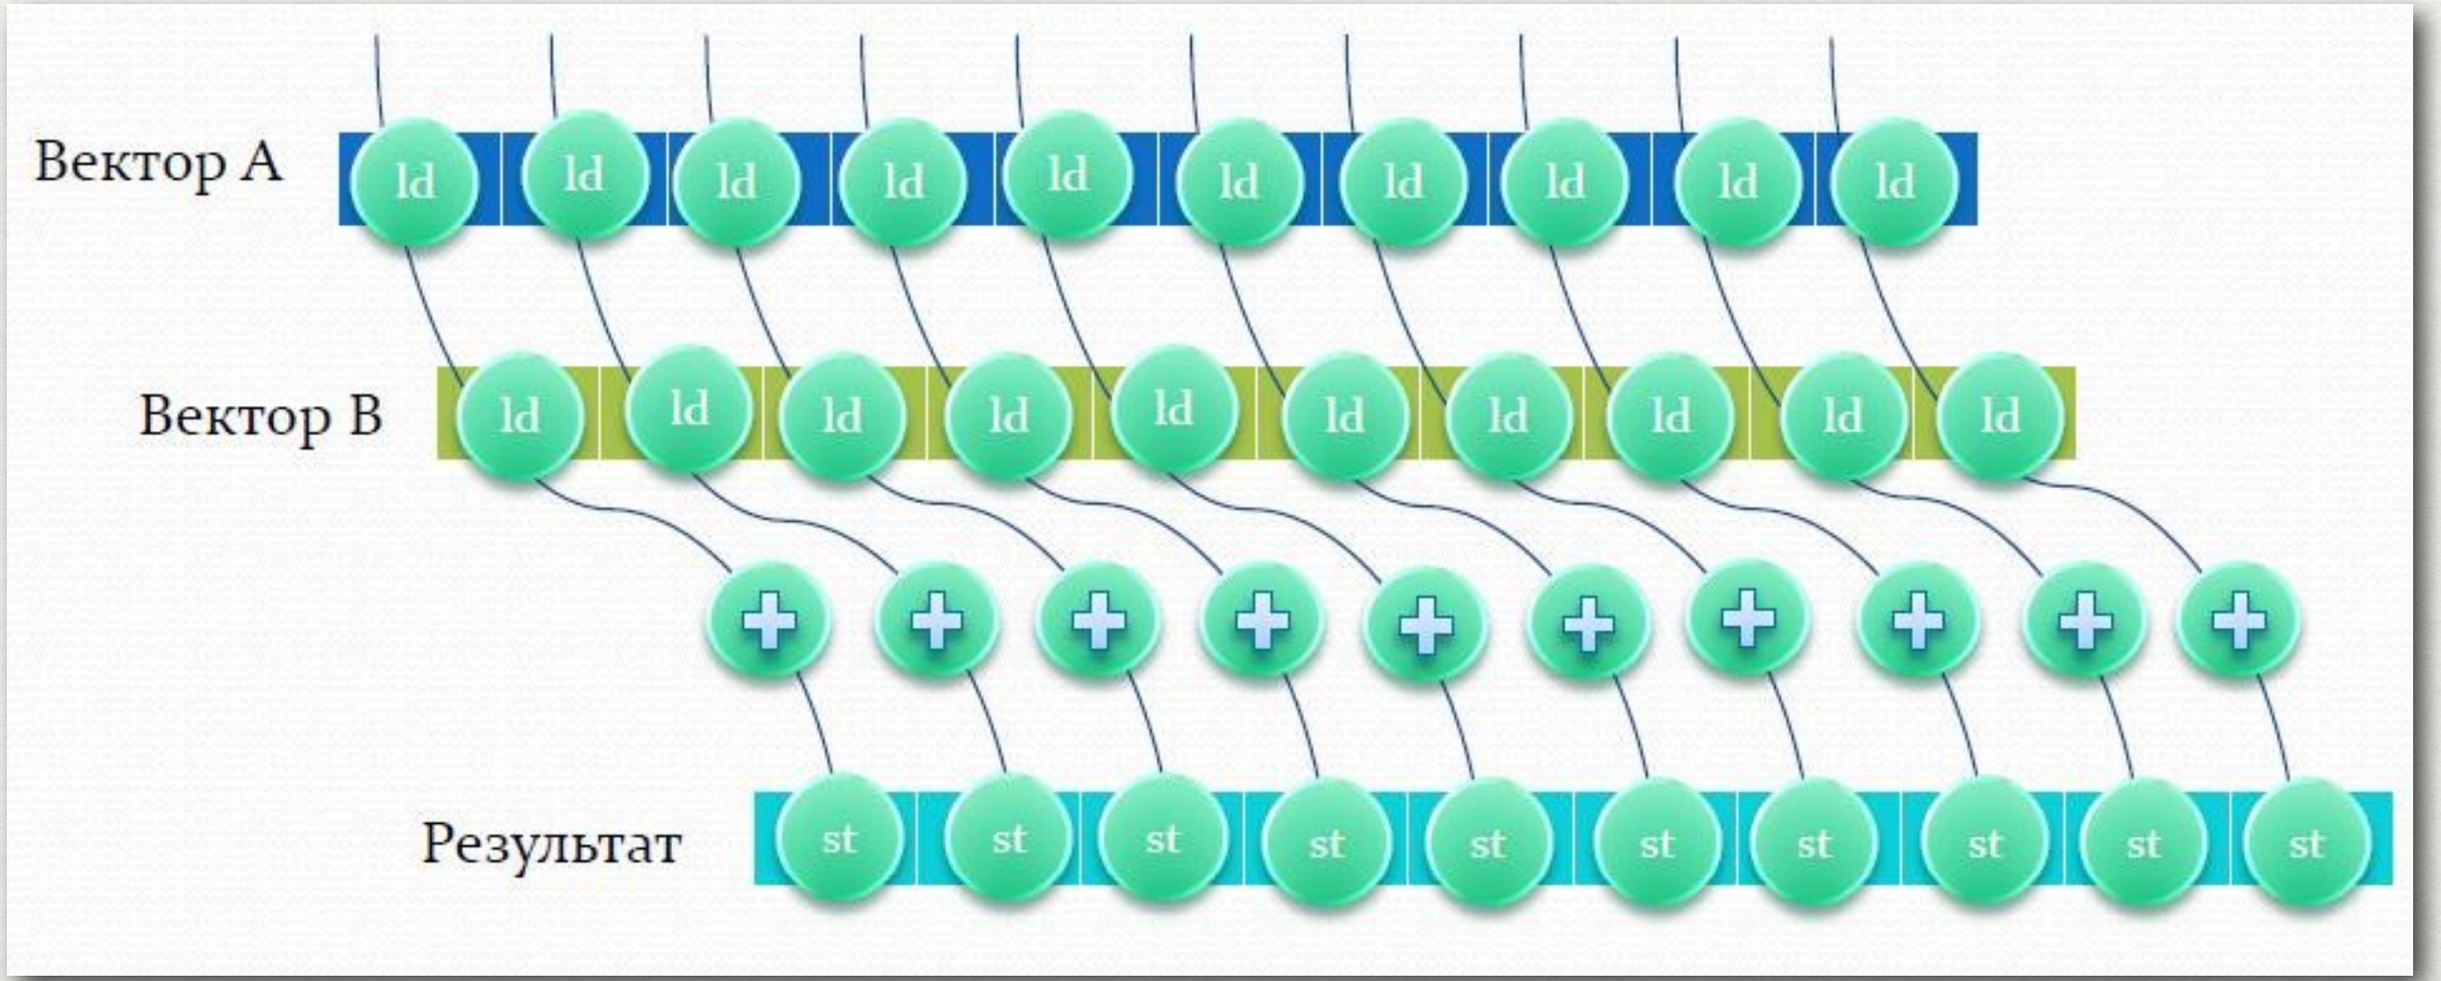

ПРИМЕР: СЛОЖЕНИЕ ВЕКТОРОВ

Как будет выглядеть CUDA-программа, складывающая вектора?

Хост-код:

```
{
    // Переслать данные с CPU на GPU
    // Запустить вычисления на N GPU-нитях
    // Скопировать результат с GPU на CPU
}
```

Девайс-код:

```
{
    c[IDX] = a[IDX] + b[IDX]; // на каждой нити
}
```

GPU: НИТИ, БЛОКИ, GRID

- Хост может запускать на GPU множества виртуальных нитей
    - Каждая из нитей использует для вычислений различные CUDA-ядра (в зависимости от типа выполняемой инструкции)
    - Нити группируются в виртуальные блоки (число блоков и размер блока задаёт пользователь, но с некоторыми аппаратными ограничениями, таким образом регулируя общее число нитей)
- Каждый потоковый мультипроцессор GPU (SM) обрабатывает несколько блоков
- Грид (от англ. Grid-сетка) – множество блоков одинакового размера, на которых запускается GPU-код
- Положение нити в блоке и блока в гриде индексируются по трём измерениям (x, y, z) - как у каждой нити, так и у каждого блока есть трехмерный индекс

РАЗМЕРЫ GRID

- Грид задаётся количеством блоков по [X, Y, Z] (размер грида в блоках) и размерами каждого блока по [X, Y, Z]
- Каждый из размеров может быть равен 1. Важные частые случаи - одномерный (Z=1) и двумерный грид (Z=1, Y=1), используемые для обработки векторов и матриц соотвественно.

двумерный грид

двумерный блок

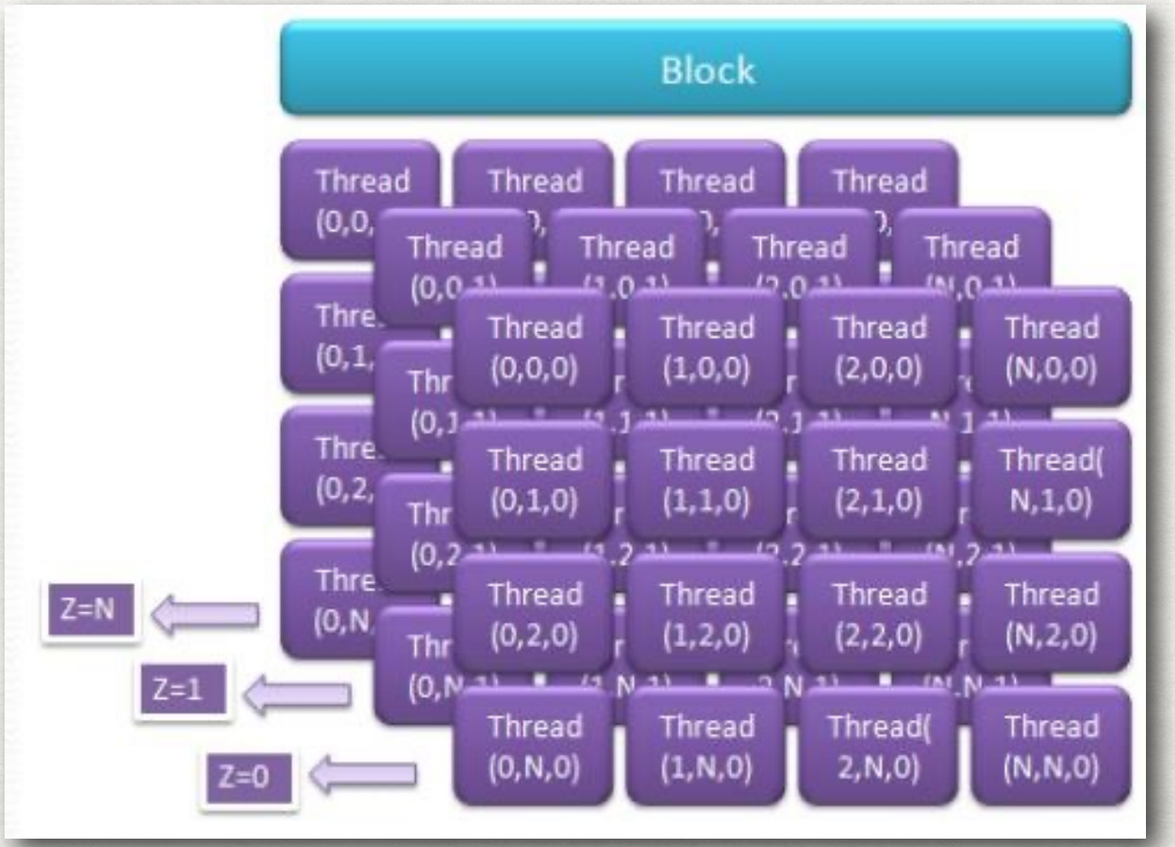

ОДНОМЕРНЫЙ ГРИД

- 4096 блоков
- в каждом блок 256 нитей
- всего 1048576 нитей

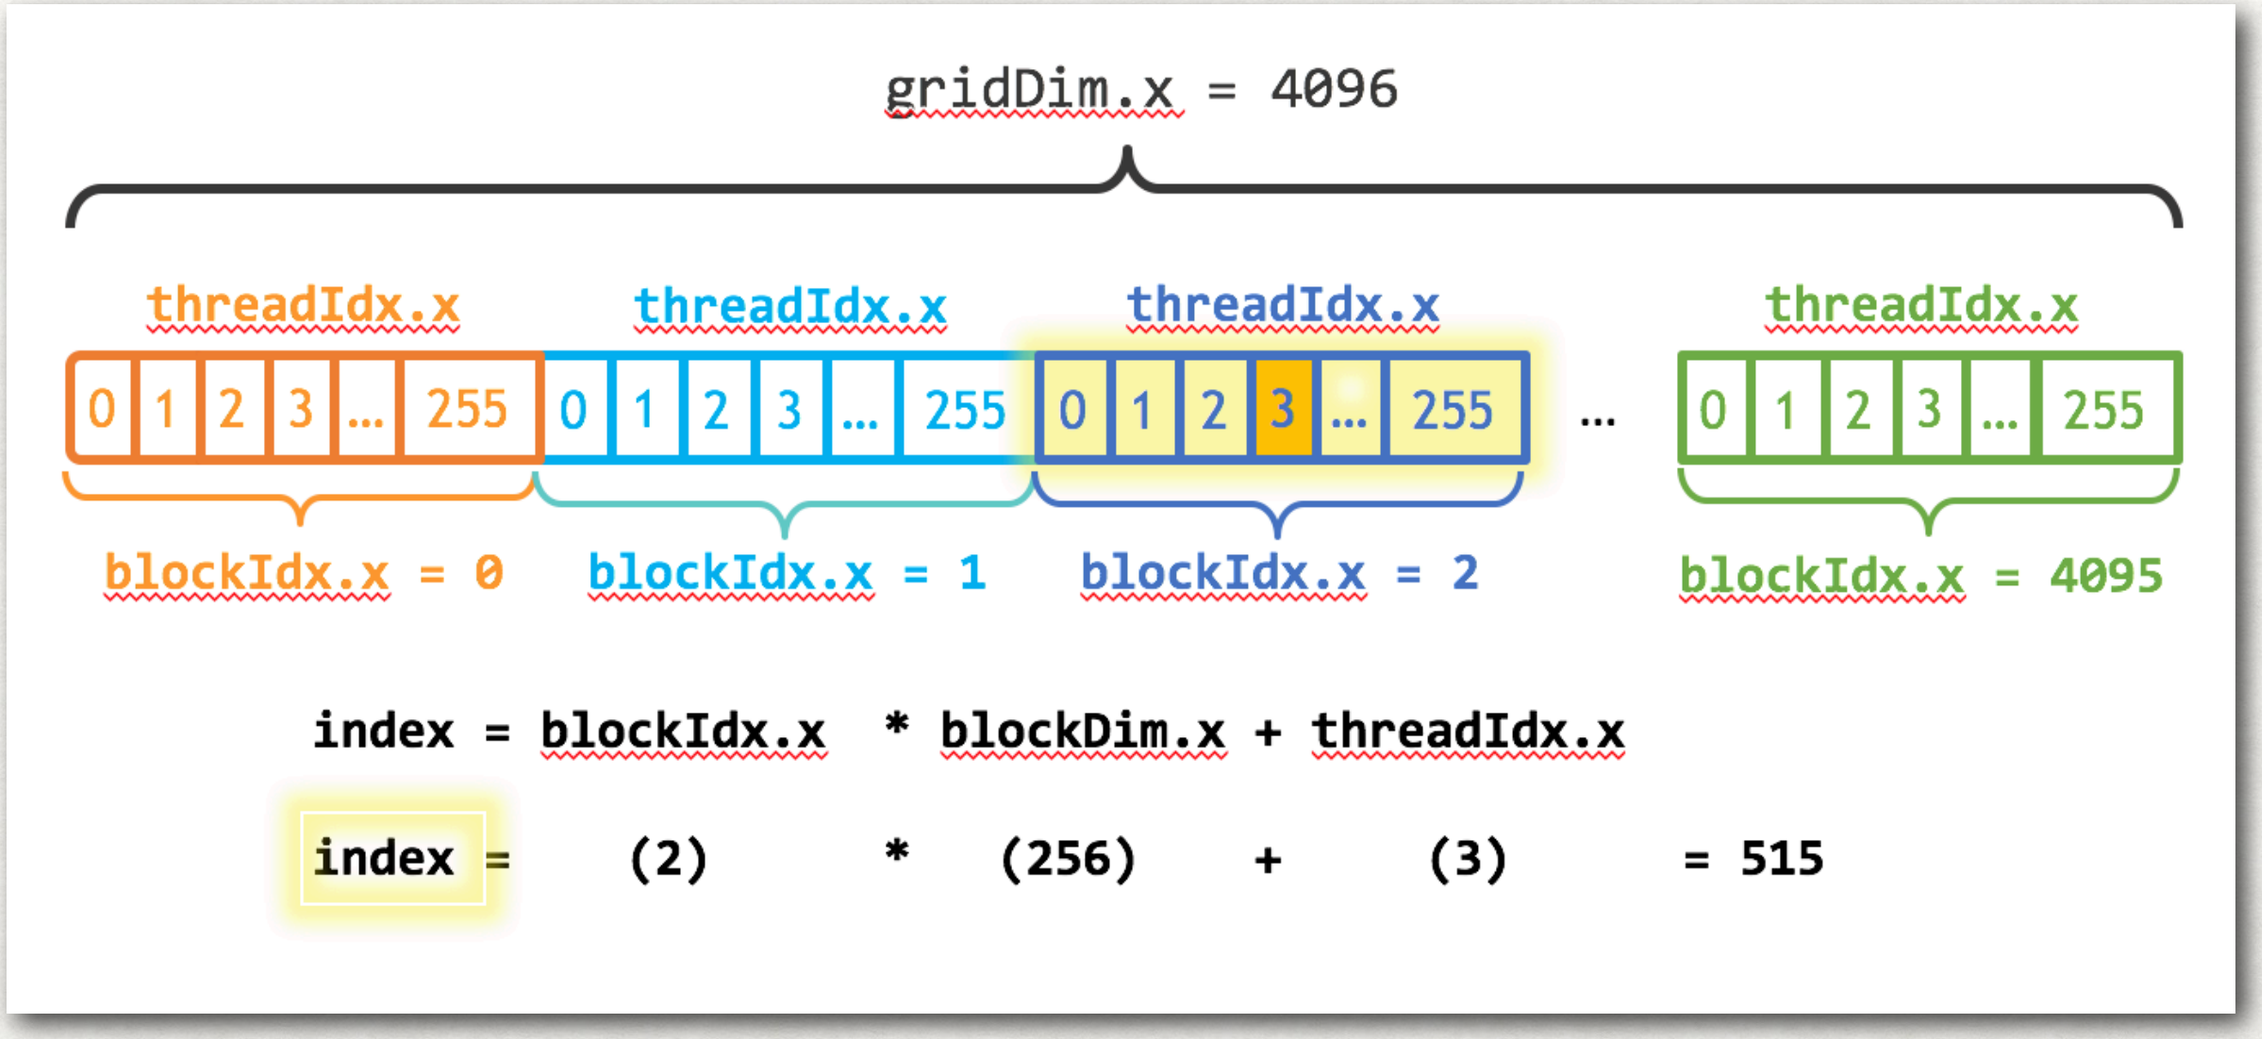

ДВУМЕРНЫЙ ГРИД И ДВУМЕРНЫЙ БЛОК

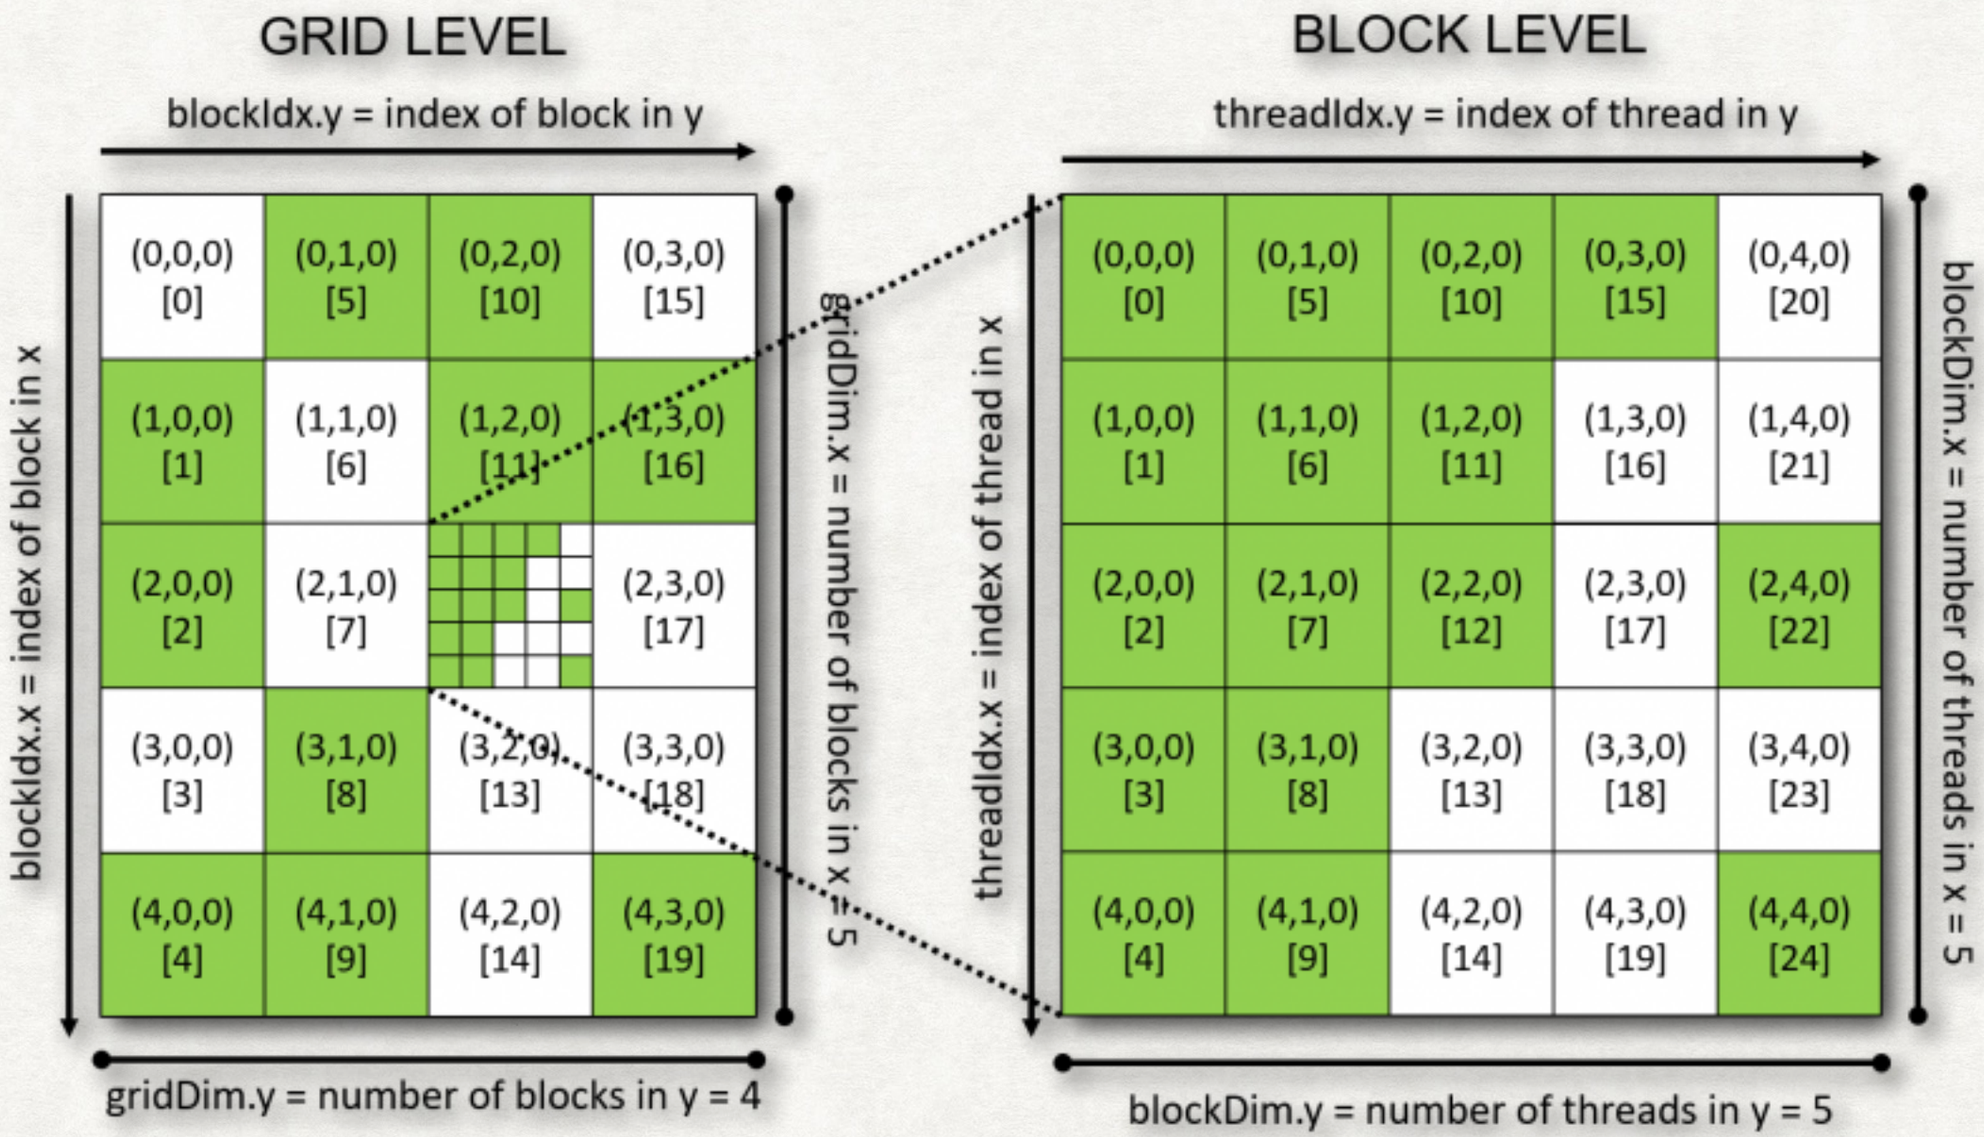

CUDA KERNEL («ЯДРО»)

- Поведение каждой из CUDA-нитей описывается специальными CUDA-ядрами
- Каждая нить выполняет копию специально оформленных функций «ядер», компилируемых для GPU
- В простейшем случае каждая из нитей выполняет одну и ту же версию кода над разными данными (data-driven параллелизм), однако в общем случае поведение нити может зависеть от её индекса
- У ядер нет возвращаемого значения (void)
- Перед описанием ядра должен присутствовать обязательный атрибут __global__
- CUDA-ядра описываются **только** в .cu файлах, компилируемых при помощи NVCC
- Пример:

```
__global__ void kernel (int param1, float *param2)
 {
     // execute device code
 }
```

ТЕРМИНОЛОГИЯ (НИТИ И ЯДРА)

- **Хост** запускает вычисление ядра на **гриде** нитей (либо просто хост запускает ядро на GPU)
- Одно и то же ядро может быть запущено на разных **гридах** (с разной конфигурацией число блоков/размер блока)
- «Ядро» – программа, поток управления, определяет что делать
- «Грид» – определяет сколько делать

СИНТАКСИС ВЫЗОВА ЯДРА

- **kernel <<< execution configuration >>> (params);**
  - “kernel”-имя ядра
  - “params”-параметры ядра,копию которых получит каждая нить
  - execution configuration-Dg,Db,Ns,S
    - dim3 Dg - размеры грида в блоках, Dg.x * Dg.y * Dg.z число блоков
    - dim3 Db - размер каждого блока, Db.x * Db.y * Db.z - число нитей в блоке
    - size_t Ns – размер динамически выделяемой общей памяти (опционально)
    - cudaStream_t S - поток, в котором следует запустить ядро (опционально)
- struct dim3 – стуктура, определённая в CUDAToolkit
  - Состоит из трех полей: unsigned x,y,z
  - Конструктор dim3(unsigned x=1, unsigned y=1, unsigned z=1)

КАК НИТЬ МОЖЕТ ОПРЕДЕЛИТЬ СВОЮ ПОЗИЦИЮ В ГРИДЕ?

- При помощи специализированных встроенных переменных:
  - threadIdx.x / threadIdx.y / threadIdx.z - индексы нити в блоке
  - blockIdx.x / blockIdx.y / blockIdx.z – индексты блока в гриде
  - blockDim.x / blockDim.y / blockDim.z – размеры блоков в нитях
  - gridDim.x / gridDim.y / gridDim.z – размеры грида в блоках

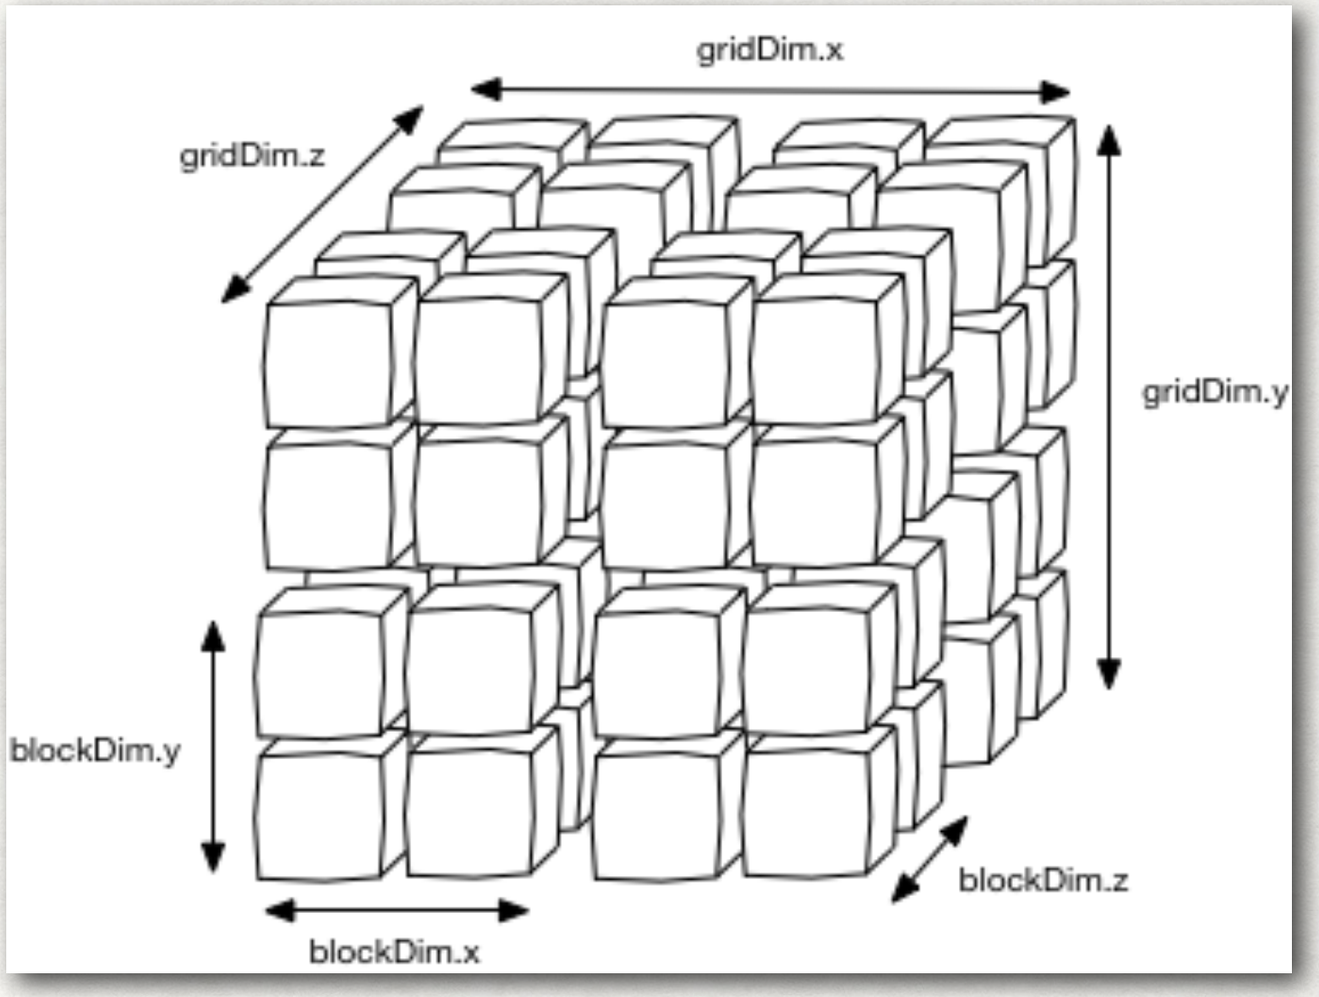

ПОЗИЦИЯ НИТИ В GRID

- Индекс нити в одномерном GRID:

```
int global_index = blockIdx.x * blockDim.x + threadIdx.x;
```

- Индекс нити в трехмерном GRID:

```
int gridSizeX = blockDim.x *
gridDim.x; int gridSizeZ = ... ;
gridSizeY = ...;
int gridSizeAll = gridSizeX * gridSizeY
* gridSizeZ;

int threadLinearIdx = (threaIdx.z *
gridSizeY + threaIdx.y) * gridSizeX +
threadIdx.x;
```

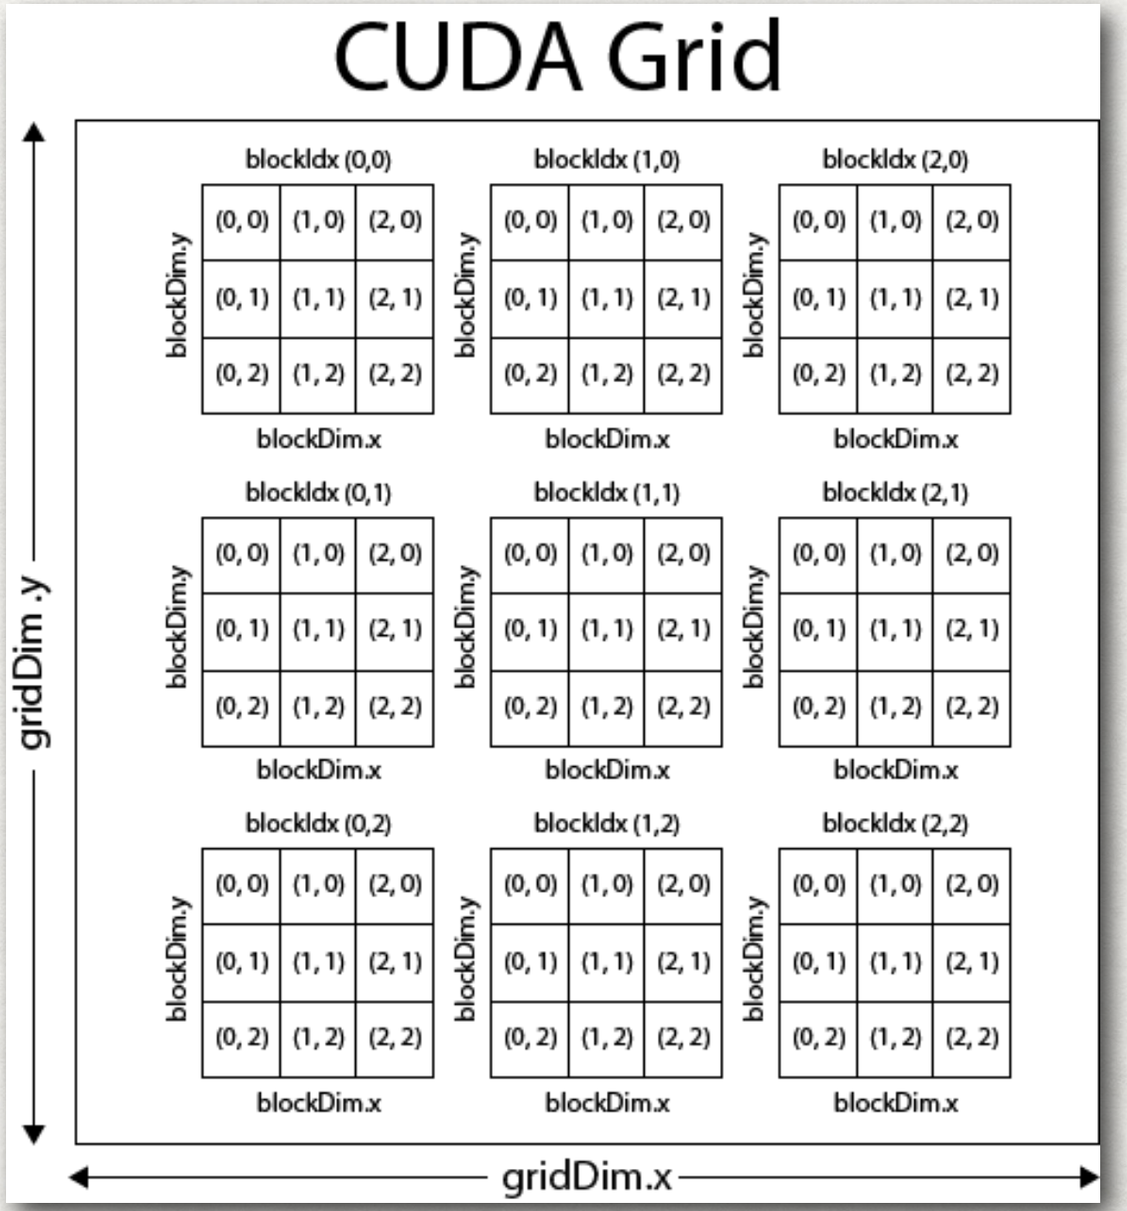

ПРИМЕР: СЛОЖЕНИЕ ВЕКТОРОВ, ДЕВАЙС-КОД

- Как реализовать сложение векторов на GPU?
- Пусть данные уже находятся в памяти GPU
- Тогда:

1. создадим грид, с числом нитей равным длине входных векторов
2. каждая нить определит свой линейный индекс i в гриде и выполнит операцию c[i] = a[i]+b[i]

- Как определить рассчитать размер грида?
    - Возьмем максимальный размер блок (1024 для P100 GPU)
    - Число блоков = (N - 1)/1024 + 1
    - При таком подходе будет создано достаточно блоков и нитей, чтобы каждая сложила соответствующие пары элементов векторов

ПРИМЕР: СЛОЖЕНИЕ ВЕКТОРОВ, ДЕВАЙС-КОД

```
__global__ void sum_kernel( int *A, int *B, int *C )
{
    int idx = blockIdx.x * blockDim.x + threadIdx.x; //определить свой индекс
    int a = A[idx]; //считать нужный элемент A
    int b = B[idx]; // считать нужный элемент B
    C[idx] = a + b; //записать результат суммирования
}
```

- Каждая нить:
  - Получает копию параметров (В данном случае, это адреса вектором на GPU)
  - Определяет своё положение в гриде threadLinearIdx
  - Считывает из входных векторов элементы с индексом threadLinearIdx и записывает их сумму в выходной вектор по индексу threadLinearIdx
  - рассчитывает один элемент выходного массива
- Вопрос: какой есть недостаток в данном коде?

ПРИМЕР: СЛОЖЕНИЕ ВЕКТОРОВ, ХОСТ-КОД

- А как же хост-код? Как скопировать данные на GPU и запустить ядро?
- Необходимо:

1. Выделить память на устройстве
2. Переслать на устройство входные данные
3. Рассчитать грид, размер грида зависит от размера задачи
4. Запустить вычисления на гриде, в конфигурации запуска указываем грид
5. Переслать результат вычислений с устройства на хост

ВЫДЕЛЕНИЕ И ОСВОБОЖДЕНИЕ ПАМЯТИ

- cudaError_t cudaMalloc (void** devPtr, size_t size)
  Выделяет size байтов линейной памяти на устройстве и возвращает указатель на выделенную память в *devPtr. Память не обнуляется. Адрес памяти выровнен по 512 байт

- cudaError_t cudaFree (void* devPtr)
  Освобождает память устройства на которую указывает devPtr.

- Аналогичны стандартным вызовам Malloc/free

КОПИРОВАНИЕ ДАННЫХ

- cudaError_t cudaMemcpy (void* dst, const void* src, size_t count, cudaMemcpyKind kind)
- Копирует count байтов из памяти, на которую указывает src в память, на которую указывает dst, kind указывает направление передачи
- cudaMemcpyHostToHost – копирование между двумя областями памяти на хосте
- cudaMemcpyHostToDevice – копирование с хоста на устройство
- cudaMemcpyDeviceToHost – копирование с устройства на хост
- cudaMemcpyDeviceToDevice – между двумя областями памяти на устройстве

СЛОЖЕНИЕ ВЕКТОРОВ, ПОЛНЫЙ ПРИМЕР

```
int main()
{
    // Size of vectors
    int n = 100000;

    // Host vectors
    double *h_a, *h_b, *h_c;

    // Size, in bytes, of each vector
    size_t bytes = n*sizeof(double);

    // Allocate memory for each vector on host
    h_a = (double*)malloc(bytes);
    h_b = (double*)malloc(bytes);
    h_c = (double*)malloc(bytes);

    int i;
    // Initialize vectors on host
    for( i = 0; i < n; i++ )
    {
       h_a[i] = sin(i)*sin(i);
       h_b[i] = cos(i)*cos(i);
    }
```

СЛОЖЕНИЕ ВЕКТОРОВ, ПОЛНЫЙ ПРИМЕР

```
// Device input vectors
double *d_a, *d_b, *d_c;

// Size, in bytes, of each vector
size_t bytes = n*sizeof(double);

// Allocate memory for each vector on GPU
cudaMalloc(&d_a, bytes);
cudaMalloc(&d_b, bytes);
cudaMalloc(&d_c, bytes);

// Copy host vectors to device
cudaMemcpy( d_a, h_a, bytes, cudaMemcpyHostToDevice);
cudaMemcpy( d_b, h_b, bytes, cudaMemcpyHostToDevice);

int blockSize, gridSize;
// Number of threads in each thread block
blockSize = 1024;
// Number of thread blocks in grid
gridSize = (n-1)/blockSize + 1;
// Execute the kernel
vecAdd<<<gridSize, blockSize>>>(d_a, d_b, d_c, n);


sum = x + y;
// Copy array back to host
cudaMemcpy( h_c, d_c, bytes, cudaMemcpyDeviceToHost );

// Release device memory
cudaFree(d_a);
cudaFree(d_b);
cudaFree(d_c);
```

КОМПИЛЯЦИЯ

(ОСОБОЕ ОТНОШЕНИЕ К .CU ФАЙЛАМ)

- При работе с CUDA используются расширения C/Си++:
  - Конструкция запуска ядра<<<....>>>
  - Встроенные переменные threadIdx, blockIdx
  - Квалификаторы __global__ __device__ и т.д.
  - ....
- Эти расширения могут быть обработаны только в *.cu файлах!
- В этих файлах можно не делать #include <cuda_runtime.h>
- Вызовы библиотечных функций вида cuda* можно располагать в *.cpp файлах
- Они будут слинкованы обычным линковщиком из библиотеки libcudart.so

НЕСКОЛЬКО ВОПРОСОВ...

- Пусть у нас есть массивно-параллельная задача (большой объем параллелизма над данными)
- Достаточно ли просто породить большое число нитей и запустить их на GPU для написания эффективной CUDA-программы?
- Нет. Крайне важно понимать, как нити обрабатываются аппаратурой GPU, о чём и пойдет речь в дальнейших лекциях.

ИЗМЕРЕНИЕ ВРЕМЕНИ РАБОТЫ ЯДРА

(БОЛЕЕ ПОДРОБНО О CUDA-СОБЫТИЯХ НА СЛЕДУЮЩИХ ЛЕКЦИЯХ)

```
cudaEvent_t start, stop;
cudaEventCreate(&start);
cudaEventCreate(&stop);

cudaMemcpy(d_x, x, N*sizeof(float), cudaMemcpyHostToDevice);
cudaMemcpy(d_y, y, N*sizeof(float), cudaMemcpyHostToDevice);

cudaEventRecord(start);
saxpy<<<(N+255)/256, 256>>>(N, 2.0f, d_x, d_y);
cudaDeviceSynchronize();
cudaEventRecord(stop);

cudaMemcpy(y, d_y, N*sizeof(float), cudaMemcpyDeviceToHost);

cudaEventSynchronize(stop);
float milliseconds = 0;
cudaEventElapsedTime(&milliseconds, start, stop);
```

ЗАДАНИЯ

ЗАДАНИЕ 1

(СЛОЖЕНИЕ ВЕКТОРОВ)

- Компиляция и запуск алгоритма сложения векторов на системе Polus
- nvcc -O3 -gencode arch=compute_52,code=sm_52 -gencode arch=compute_60,code=sm_60 main.cu
- Самостоятельно реализовать проверку корректности результата (host и device)
- Доработать программу, чтобы она могла производить сложение векторов произвольного размера

ЗАДАНИЕ 2

(РАБОТА С ДВУМЕРНЫМ ГРИДОМ)

- Реализуем ядро транспонирования матрицы a[i][j] = a[j][i] (можно без хост кода, итоговую версию запустим в конце дня)
- Как сконфигурировать грид для матрицы размера N?
- Какую операцию будет производить каждая из нитей?
- Как необходимо хранить матрицу?
- Как скопировать матрицу в память GPU и обратно?

ВОПРОСЫ?